

Machine Learning Homework 2

資工碩一 r09922055 陳柏妤

1. (c)

(a) (7, 8, 9), (17, 18, 19), (27, 28, 29) 三點共線，無法 shatter

(b)(c)(d)(e)

用 (7, 8, 9), (15, 16, 17), (21, 23, 25) 三個點解平面公式

得到 $x_1 - 2x_2 + x_3 = 0$

(b) (1, 1, 1) 在 $x_1 - 2x_2 + x_3 = 0$ 上

(c) (1, 1, 3) 不在 $x_1 - 2x_2 + x_3 = 0$ 上

(d) (1, 3, 5) 在 $x_1 - 2x_2 + x_3 = 0$ 上

(e) (1, 2, 3)、(4, 5, 6) 在 $x_1 - 2x_2 + x_3 = 0$ 上

by 2D perceptron 的 $d_{vc} = 3$ ，(b)(d)(e) 無法 shatter

2. (d)

2D perceptron 的 $d_{vc} = 3$ ，當 $N=4$ 的時候 $m_h(N) < 2^N$ ，因此 (a)(b)(c) 一定錯

$w_1 w_2 = 0 \Rightarrow w_1 = 0 \vee w_2 = 0$ （垂直或水平的線）

說明：growth function of axis-aligned perceptrons $\leq 4N - 2$

假設有一組 N 個 input $(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$ ，其中 N 個 x 座標不重複、 N 個 y 座標不重複。把這些點投影到 x 軸和 y 軸後，by “growth function of 1D perceptron”

可分別在 x 軸和 y 軸找到 $2N$ 種 perceptron 的組合 \Rightarrow 共 $4N$ 種

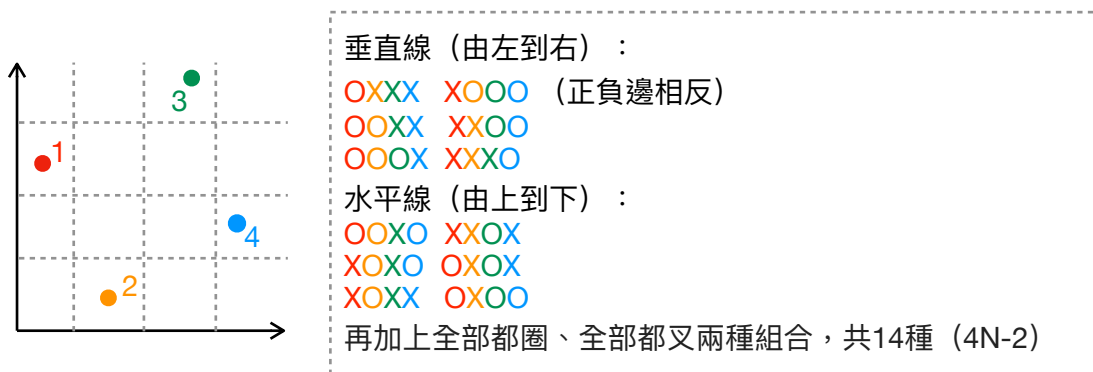
而全部圈和全部叉的組合會被重複計算，扣掉之後會變成 $4N-2$ 種

因此，growth function of axis-aligned perceptrons $\leq 4N - 2$ （因為可能有重複）

說明：可以找到一組點使得 growth function of axis-aligned perceptrons $= 4N - 2$

若能找到一組點符合以下條件：「在 x 座標形成的 $2N$ 種 perceptron」與「在 y 座標形成的 $2N$ 種 perceptron」，除了全部圈和全部叉的組合之外，其他的 dichotomy 都不重複。則可以說 growth function of axis-aligned perceptrons $= 4N - 2$

考慮下圖四點的排列，6 條灰色虛線為不同的 hypothesis，可以產生 14 種 dichotomy



3. (c)

(a) 證： $d_{vc} \geq 2$ (There are some 2 inputs we can shatter)



1		$x - y + 5 = 0$	point(2, 14) = -, point(5, 13) = -
2		$x - y + 10 = 0$	point(2, 14) = -, point(5, 13) = +
3		$x - y + 15 = 0$	point(2, 14) = +, point(5, 13) = +
4		$-x - y + 17 = 0$	point(2, 14) = +, point(5, 13) = -

(b) 證： $d_{vc} \leq 2$ (We can not shatter any set of 3 inputs)

假設有三個 input point $(x_1^{(1)}, x_1^{(2)}), (x_2^{(1)}, x_2^{(2)}), (x_3^{(1)}, x_3^{(2)})$

$$X = \begin{bmatrix} 1 & x_1^{(1)} & x_1^{(2)} \\ 1 & x_2^{(1)} & x_2^{(2)} \\ 1 & x_3^{(1)} & x_3^{(2)} \end{bmatrix}, \vec{x}_1 = (1, x_1^{(1)}, x_1^{(2)}), \vec{x}_2 = (1, x_2^{(1)}, x_2^{(2)}), \vec{x}_3 = (1, x_3^{(1)}, x_3^{(2)})$$

· 如果 $\vec{x}_1, \vec{x}_2, \vec{x}_3$ linear dependent \Rightarrow by 上課證明，一定不能 shatter

· 如果 $\vec{x}_1, \vec{x}_2, \vec{x}_3$ linear independent (可作為三維空間的 basis)

則存在唯一一組 (a_1, a_2, a_3) 使得三維向量 \vec{z} 被表示為： $\vec{z} = a_1\vec{x}_1 + a_2\vec{x}_2 + a_3\vec{x}_3$

左右同乘 $w^T \Rightarrow w^T\vec{z} = a_1w^T\vec{x}_1 + a_2w^T\vec{x}_2 + a_3w^T\vec{x}_3$

此時若 $\vec{z} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$ ，上式會變 $w_0 = a_1w^T\vec{x}_1 + a_2w^T\vec{x}_2 + a_3w^T\vec{x}_3 = a_1y_1 + a_2y_2 + a_3y_3$

因此，當 $w_0 > 0$ 時，三個點無法 shatter

(如：設 a_1, a_2, a_3 皆大於零，必無法產生 $(y_1, y_2, y_3) = (-, -, -)$ 這種 dichotomy)

4. (b)

$x_1^2 + x_2^2 + x_3^2$ 可看作是三維空間中的點到原點距離的平方，而此時 ring hypothesis 就可看作是課堂上 “Growth Function for Positive Intervals” 的問題。即：在數線上畫 N 個點（每個點的值是 x_n 到原點距離的平方），求 Positive Intervals 的 Growth Function。

by 課堂上的推導， $m_H(N) = C_2^{N+1} + 1$ ，答案為 (b)

5. (b)

承上題與課堂講義 “The VC Dimension, P.5”，Positive Intervals 的 VC dimension=2。因此 ring hypothesis set 的 VC dimension=2。

6. (d)

$$\begin{aligned}
 \text{(a) 證: } |E_{out}(g) - E_{out}(g^*)| &\leq |E_{out}(g) - E_{in}(g)| + |E_{in}(g^*) - E_{out}(g^*)| \\
 |E_{out}(g) - E_{out}(g^*)| &= |E_{out}(g) - E_{in}(g) + E_{in}(g) - E_{out}(g^*)| \\
 &\leq |E_{out}(g) - E_{in}(g) + E_{in}(g^*) - E_{out}(g^*)| \\
 &\leq |E_{out}(g) - E_{in}(g)| + |E_{in}(g^*) - E_{out}(g^*)| \quad (\text{三角不等式})
 \end{aligned}$$

$$\text{(b) 證: For every } g, \text{ with probability more than } 1 - \delta, |E_{in}(g) - E_{out}(g)| \leq \sqrt{\frac{8}{N} \ln\left(\frac{4m_H(2N)}{\delta}\right)}$$

VC Bound : For any $g = A(D) \in H$ and statistical large D ,

$$P[|E_{in}(h) - E_{out}(h)| > \epsilon] \leq 4m_H(2N) \exp\left(-\frac{1}{8}\epsilon^2 N\right)$$

$$\text{set } \delta = 4m_H(2N) \exp\left(-\frac{1}{8}\epsilon^2 N\right)$$

$$\Rightarrow \frac{\delta}{4m_H(2N)} = \exp\left(-\frac{1}{8}\epsilon^2 N\right)$$

$$\Rightarrow \ln\left(\frac{4m_H(2N)}{\delta}\right) = \frac{1}{8}\epsilon^2 N$$

$$\Rightarrow \sqrt{\frac{8}{N} \ln\left(\frac{4m_H(2N)}{\delta}\right)} = \epsilon$$

by Lecture7 P.21, For every g , with probability more than $1 - \delta$, $|E_{in}(g) - E_{out}(g)| \leq \epsilon$

$$\Rightarrow |E_{in}(g) - E_{out}(g)| \leq \sqrt{\frac{8}{N} \ln\left(\frac{4m_H(2N)}{\delta}\right)}$$

$$\text{(c) 證: } |E_{out}(g) - E_{out}(g^*)| \leq 2\sqrt{\frac{8}{N} \ln\left(\frac{4m_H(2N)}{\delta}\right)}$$

$$\begin{aligned}
 \text{by (a), } |E_{out}(g) - E_{out}(g^*)| &\leq |E_{out}(g) - E_{in}(g)| + |E_{in}(g^*) - E_{out}(g^*)| \\
 &\leq \sqrt{\frac{8}{N} \ln\left(\frac{4m_H(2N)}{\delta}\right)} + \sqrt{\frac{8}{N} \ln\left(\frac{4m_H(2N)}{\delta}\right)} \\
 &\leq 2\sqrt{\frac{8}{N} \ln\left(\frac{4m_H(2N)}{\delta}\right)}
 \end{aligned}$$

7. (d)

a. 希望 d_{vc} 最大 \Rightarrow M 個 hypothesis 各產生不同的 M 種 dichotomy 時, d_{vc} 會最大

b. d_{vc} 的意含: 最多可 shatter d_{vc} 個點 \Rightarrow 可對 d_{vc} 個點產生 $2^{d_{vc}}$ 種不同的 dichotomy

綜合以上兩點, 可知 $M \geq 2^{d_{vc}} \Rightarrow d_{vc} \leq \lfloor \log_2 M \rfloor$

8. (d)

boolean function 輸出的值只和 input 中 1 的數量有關, 而 $\{-1, +1\}^k$ 是 k-dimensional 的資料點, 因此 1 的數量只會介於 0~k 之間 (k+1 種不同的 input)。此時若這 k+1 個 input 在不同的 h 中皆有 -1 和 +1 兩種輸出, 則可以對 k+1 個點產生 2^{k+1} 種 dichotomy \Rightarrow shattered!

(因為只有 k+1 種不同的 input, 若 $N > k+1$, 則必有兩個點的 output 會相同 \Rightarrow 無法 shatter)

9. (c)

$d_{vc} = d \Rightarrow$ 最大的 non-break point = d ($d+1$ 是最小的 break point) $\Rightarrow d_{vc} \geq d$ 且 $d_{vc} \leq d$

- maximum non-break point = d ($d_{vc} \geq d$) : There are 'some d inputs' we can shatter
- minimum break point = $d+1$ ($d_{vc} \leq d$) : We can't not shatter any set of $d+1$ input

而 "any set of $d + 1$ distinct inputs is not shattered by H " 也包含了 "some set of $d + 1$ distinct inputs is not shattered by H "

所以第一點、第六點和最後一點是 necessary condition

10. (c)

(c) by <https://cs.nyu.edu/~mohri/ml16/sol2.pdf> 2(b)

$\{h_\alpha : h_\alpha(x) = \text{sign}(\sin(\alpha \cdot x))\}$

設有 m ($m \in N$) 個 inputs $(x_1, x_2, \dots, x_m) = (2^{-1}, 2^{-2}, \dots, 2^{-m})$

輸出的 labels $(y_1, y_2, \dots, y_m) \in \{-1, +1\}^m$

此時造一個 $\alpha = \pi(1 + \sum_{i=1}^m 2^i y'_i)$, $y'_i = \frac{1 - y_i}{2}$ (即: $y'_i \begin{cases} 1, & \text{if } y_i = -1 \\ 0, & \text{if } y_i = 1 \end{cases}$)

for any $j \in [1, m]$ ($j \in N$),

$$\begin{aligned} \alpha \cdot x_j &= \alpha \cdot 2^{-j} = \pi(1 + \sum_{i=1}^m 2^i y'_i) \cdot 2^{-j} = \pi(2^{-j} + \sum_{i=1}^m 2^{i-j} y'_i) \\ &= \pi(2^{-j} + \sum_{i=1}^{j-1} 2^{i-j} y'_i + y'_j + \sum_{i=j+1}^m 2^{i-j} y'_i) = \pi(\sum_{i=1}^{j-1} 2^{-i} y'_i + 2^{-j} + y'_j) \end{aligned}$$

(橘色區的 $i > j$, 此時 $\pi \sum_{i=j+1}^m 2^{i-j} y'_i$ 為 2π 的倍數, 對 $\sin(\alpha \cdot x)$ 沒影響。省略)

可以得到 $\alpha \cdot x_j = \pi(\sum_{i=1}^{j-1} 2^{-i} y'_i + 2^{-j} + y'_j)$ 的 upper 和 lower bound :

$$\cdot \pi(\sum_{i=1}^{j-1} 2^{-i} y'_i + 2^{-j} + y'_j) \leq \pi(\sum_{i=1}^j 2^{-i} + y'_j) \quad (\text{因為 } y'_i = 0 \text{ or } 1) < \pi(1 + y'_j)$$

$$\cdot \pi(\sum_{i=1}^{j-1} 2^{-i} y'_i + 2^{-j} + y'_j) > \pi(y'_j)$$

因此, $\begin{cases} \pi < \alpha \cdot x_j < 2\pi, & \text{if } y'_j = 1, y_j = -1 \\ 0 < \alpha \cdot x_j < \pi, & \text{if } y'_j = 0, y_j = 1 \end{cases}$, 則 $h_\alpha(x) \begin{cases} -1, & \text{if } y_j = -1 \\ 1, & \text{if } y_j = 1 \end{cases}$

$\forall m \in N$, 無論 (y_1, y_2, \dots, y_m) 長怎樣, 都能造出 α s.t $\text{sign}(\sin(\alpha \cdot x_i)) = y_i, i \in [1, m]$

11. (d)

$$E_{out}(h, \tau) = (1 - E_{out}(h, 0)) \cdot \tau + E_{out}(h, 0) \cdot (1 - \tau)$$

· $(1 - E_{out}(h, 0)) \cdot \tau$: 原本預測正確的資料有 τ 的機率預測錯誤

· $E_{out}(h, 0) \cdot (1 - \tau)$: 原本預測錯誤的資料有 $1 - \tau$ 的機率仍然是錯的


$$E_{out}(h, \tau) = \tau - E_{out}(h, 0) \cdot \tau + E_{out}(h, 0) - E_{out}(h, 0) \cdot \tau = \tau + E_{out}(h, 0) \cdot (1 - 2\tau)$$

$$E_{out}(h, 0) = \frac{E_{out}(h, \tau) - \tau}{1 - 2\tau}$$

12. (b)

如右圖，using squared error 計算 $y \neq f(x)$ 時的 $E_{out}(f)$

$$\begin{aligned} E_{out}(f) &= \frac{1}{3} \cdot (0.1 \cdot (2 - 1)^2 + 0.2 \cdot (3 - 1)^2) + \frac{1}{3} \cdot (0.1 \cdot (3 - 2)^2 + 0.2 \cdot (1 - 2)^2) \\ &\quad + \frac{1}{3} \cdot (0.1 \cdot (1 - 3)^2 + 0.2 \cdot (2 - 3)^2) \\ &= \frac{1}{3} \cdot (0.1 + 0.8) + \frac{1}{3} \cdot (0.1 + 0.2) + \frac{1}{3} \cdot (0.4 + 0.2) \\ &= \frac{1}{3} \cdot (1.8) = 0.6 \end{aligned}$$



13. (b)

$$\cdot f(x) = 1 \text{ 時, } f_*(x) = 1 \cdot 0.7 + 2 \cdot 0.1 + 3 \cdot 0.2 = 0.7 + 0.2 + 0.6 = 1.5$$

$$\cdot f(x) = 2 \text{ 時, } f_*(x) = 2 \cdot 0.7 + 3 \cdot 0.1 + 1 \cdot 0.2 = 1.4 + 0.3 + 0.2 = 1.9$$

$$\cdot f(x) = 3 \text{ 時, } f_*(x) = 3 \cdot 0.7 + 1 \cdot 0.1 + 2 \cdot 0.2 = 2.1 + 0.1 + 0.4 = 2.6$$

$$\Delta(f, f_*) = \frac{1}{3} \cdot (1 - 1.5)^2 + \frac{1}{3} \cdot (2 - 1.9)^2 + \frac{1}{3} \cdot (3 - 2.6)^2 = \frac{0.25 + 0.01 + 0.16}{3} = 0.14$$

14. (d)

$$\text{VC bound : } P[|E_{in}(h) - E_{out}(h)| > \epsilon] \leq 4m_H(2N)\exp(-\frac{1}{8}\epsilon^2N)$$

by 題目敘述，decision stump model 的 growth function 是 $2N$ 、 $d_{vc} = 2$

$$4m_H(2N)\exp(-\frac{1}{8}\epsilon^2N) = 4(4N)\exp(-\frac{1}{8}\epsilon^2N) = 16N\exp(-\frac{1}{8}\epsilon^2N)$$

$$\text{帶入 } \epsilon = 0.1, \delta = 0.1 \Rightarrow 16N\exp(-\frac{1}{8}\epsilon^2N) = 16N\exp(-0.00125N)$$

依序帶入 $N=6000, 8000, 10000, 12000, 14000$

$$16N\exp(-0.00125N) = 53.096, 5.811, 0.596, 0.059, 0.006$$


找最小的 N 使得 $16N\exp(-0.00125N) \leq 0.1$ ，答案為 12000

15. (b)

因為 $f(x) = \text{sign}(x)$ (即 : $f(x \leq 0) = -1$ 、 $f(x > 0) = +1$)

θ 介於 -1 到 1 之間 , $h_{+1,\theta}(x \leq \theta) = -1$ 、 $h_{+1,\theta}(x > \theta) = +1$

因此會有以下兩種錯誤的情形：



· $\theta < 0$ 時 , $-\theta < x \leq 0$ 會預測錯誤 $\Rightarrow E_{out}(h_{+1,\theta}, 0) = \frac{|\theta|}{2}$

· $\theta \geq 0$ 時 , $0 < x \leq \theta$ 會預測錯誤 $\Rightarrow E_{out}(h_{+1,\theta}, 0) = \frac{|\theta|}{2}$

16. (d)

17. (b)

18. (e)

19. (c)

20. (a)

```

In [219]: import numpy as np
def train(times, set_size, tau):
    out_minus_in = 0
    for T in range(times):
        print(T, end='\r')
        ## get x_set, y_set
        x_set = np.sort(np.random.uniform(-1, 1, set_size))
        y_set = np.zeros([set_size])
        num_negative = 0
        for i in range(set_size):
            y_set[i] = np.sign(x_set[i])
            if y_set[i]==0:
                y_set[i] = -1
            temp = np.random.uniform(0, 1)
            if temp<=tau:
                y_set[i] *= -1
            if y_set[i]==-1:
                num_negative += 1
        ##dp_table, E_in
        dp_table = np.zeros([2, set_size])
        dp_table[0][0] = set_size-num_negative ## s=-1 預測錯的個數
        dp_table[1][0] = num_negative ## s=1 預測錯的個數
        for i in range(1, set_size):
            if y_set[i-1]==-1:
                dp_table[0][i] = dp_table[0][i-1] + 1
                dp_table[1][i] = dp_table[1][i-1] - 1
            elif y_set[i-1]==1:
                dp_table[0][i] = dp_table[0][i-1] - 1
                dp_table[1][i] = dp_table[1][i-1] + 1
        E_in = np.min(dp_table) / set_size
        ##s, theta
        index = np.unravel_index(np.argmin(dp_table, axis=None), dp
        _table.shape)
        if index[0] == 0:
            s = -1
        elif index[0] == 1:
            s = 1
        which_theta = index[1]
        if which_theta == 0:
            theta = -1
        else:
            theta = (x_set[which_theta-1] + x_set[which_theta]) / 2
        ##E_out
        if s == -1:
            E_out = 1 - (0.5 * abs(theta))
        elif s == 1:
            E_out = 0.5 * abs(theta)
        E_out = E_out*(1-(2*tau))+tau

        out_minus_in += (E_out-E_in)
    mean = out_minus_in/times
    return mean

```

```
In [220]: mean_16 = train(10000, 2, 0)
          print("mean_16", mean_16)

mean_16 0.2907575302757793
```

```
In [221]: mean_17 = train(10000, 20, 0)
          print("mean_17", mean_17)

mean_17 0.024181985529829673
```

```
In [222]: mean_18 = train(10000, 2, 0.1)
          print("mean_18", mean_18)

mean_18 0.36722770808211214
```

```
In [223]: mean_19 = train(10000, 20, 0.1)
          print("mean_19", mean_19)

mean_19 0.05157750106317468
```

```
In [224]: mean_20 = train(10000, 200, 0.1)
          print("mean_20", mean_20)

mean_20 0.005457546034295806
```